

Análisis de Fraude Transaccional

Simulación, detección y evaluación de riesgo

Autor: Juan Manuel Pizzorno

Fecha: 2026

Resumen Ejecutivo

Este proyecto simula un entorno de detección de fraude en transacciones digitales con el objetivo de identificar patrones de riesgo y evaluar estrategias de mitigación. Se desarrolló un dataset sintético que replica comportamientos fraudulentos comunes y se aplicaron técnicas de análisis exploratorio, ingeniería de variables y modelado predictivo. Los resultados permiten identificar señales claras de fraude, aunque deben interpretarse considerando las limitaciones propias de un entorno simulado.

Objetivo

Analizar patrones de fraude a nivel transaccional, cuantificar su impacto económico y evaluar estrategias de detección que permitan reducir el riesgo sin afectar la experiencia del usuario.

Construcción del Dataset

- 50.000 transacciones simuladas
- 1.000 usuarios
- Tasa de fraude del 2%
- Período de análisis de 30 días

Tipos de fraude simulados:

- Montos anómalos respecto al comportamiento del usuario
- Inconsistencias geográficas entre usuario y transacción
- Cuentas nuevas con compras de alto valor

Análisis Exploratorio

Se identificaron diferencias significativas entre transacciones fraudulentas y legítimas. Las transacciones fraudulentas presentan montos más elevados y menor antigüedad de cuenta, lo que sugiere comportamientos atípicos.

Ingeniería de Variables

- Ratio entre monto de transacción y promedio histórico del usuario
- Flag de cuenta nueva
- Inconsistencia de país entre usuario y transacción

Estas variables permiten capturar desviaciones respecto al comportamiento esperado, mejorando la capacidad de detección de fraude.

Modelado

Se implementó un modelo de regresión logística para clasificar transacciones como fraudulentas o legítimas. El modelo alcanzó métricas cercanas al 100%, debido a la claridad de los patrones definidos en el dataset.

Decisión de Negocio

Se simuló un sistema de scoring de riesgo que permite establecer umbrales para la detección de fraude. Este enfoque facilita el balance entre la detección de fraude y la reducción de falsos positivos.

Limitaciones

- Dataset sintético sin ruido real
- Patrones de fraude definidos explícitamente
- Alta separabilidad entre clases

Próximos Pasos

- Incorporar ruido y casos ambiguos
- Agregar variables como medio de pago o comportamiento del usuario
- Evaluar modelos más complejos
- Implementar pruebas A/B

Conclusión

El proyecto demuestra cómo el análisis de datos y la ingeniería de variables permiten identificar patrones de fraude y tomar decisiones alineadas con objetivos de negocio. Asimismo, resalta la importancia de balancear la detección de fraude con la experiencia del usuario.